

Dawid Pawliczek

Union–Find

Dowód, że koszt amortyzowany wynosi $O(n \log^* n)$

Definicje

- Każdy węzeł x ma atrybut $rank(x)$.
- $makeSet(x)$ ustawia $rank(x) = 0$ i $parent(x) = x$.
- $union(x, y)$ łączy dwa zbiory: korzeniem zostaje ten, którego ranga jest większa; przy rangach równych wybieramy dowolny i *zwiększamy* jego rangę o 1.
- $find(x)$ zwraca korzeń zbioru oraz ustawia dla każdego odwiedzonego węzła $parent =$ korzeń (kompresja ścieżek).

Lemat 1

Twierdzenie. Wysokość każdego drzewa jest nie większa niż ranga jego korzenia.

Dowód. Rangę zwiększamy tylko wtedy, gdy łączymy dwa drzewa o tej samej randze r , wybierając jeden korzeń i nadając mu rangę $r + 1$. Wysokość nowego drzewa rośnie wówczas najwyżej o 1, czyli również maksymalnie do $r + 1$. Kroki indukcyjne zachowują tezę, a dla rangi 0 jest ona oczywista. \square

Uwaga: kompresja ścieżek może zmniejszyć wysokość drzewa, dlatego nierówność nie działa w drugą stronę.

Lemat 2

Twierdzenie. Dla każdego węzła x $rank(x) \leq \lfloor \log_2 n \rfloor$.

Dowód. Aby ranga węzła osiągnęła wartość r , musiało się połączyć co najmniej 2^r elementów: każdy wzrost rangi wymaga scalenia dwóch drzew o tej samej randze. Zatem $2^r \leq n$, skąd $r \leq \log_2 n$. \square

Grupowanie rang a \log^*

Zamiast śledzić każdy *pojedynczy* wzrost rangi (jest ich $\leq \log_2 n$), grupujemy je w **poziomy**. Definiujemy

$$F(0) = 1, \quad F(i) = 2^{F(i-1)} \quad (i \geq 1).$$

Poziom i zawiera wszystkie rangi $F(i-1) < r \leq F(i)$. Liczba poziomów potrzebnych, by objąć maksymalną rangę $\leq \log_2 n$, wynosi $\log^* n$, ponieważ $F(\log^* n) \geq n$.

Ile razy węzeł może zmienić rodzica?

Podczas $find$ każdy odwiedzony węzeł v ustawia $parent(v) \leftarrow$ korzeń czyli na węzeł o *ściśle większej* randze. Węzeł może więc „awansować” co najwyżej: raz z poziomu 0 do 1, raz z 1 do 2, ... Łącznie najwyżej $\log^* n$ razy.

Koszt operacji

- **union** – koszt $O(1)$.
- **find** – dla każdego odwiedzonego węzła:
 - odczyt **parent** – $O(1)$,
 - zapis nowego **parent** – *co najwyżej* $\log^* n$ razy w całej sekwencji operacji.

Przy n elementach łączny koszt wszystkich zmian rodzica to $O(n \log^* n)$, a pozostałe odczyty i **union**-y mieszczą się w $O(n)$. Stąd amortyzowany koszt sekwencji $m = O(n)$ operacji wynosi

$$O(n \log^* n).$$